

Unity Tabanlı 2D Bomberman Ortamında Pekiştirmeli Öğrenme Ajanı Geliştirilmesi

Çağla Ökmen

Bursa Teknik Üniversitesi

Özet

Bu çalışma, karmaşık ve dinamik bir ızgara (grid) ortamı olan Bomberman oyunu için Çok Katmanlı Algılayıcı (Multi-Layer Perceptron - MLP) tabanlı pekiştirmeli öğrenme (RL) ile kural tabanlı bir A* (A-Star) güvenlik katmanını algoritmalarını birleştiren özgün bir hibrit mimari sunmaktadır. Pekiştirmeli öğrenme ajanlarının seyrek ödül ve ölümcül ceza durumlarında yaşadığı istikrarsızlık sorununu gidermek amacıyla, karar alma süreci A* algoritmasına dayalı bir risk haritası ve müfredat tabanlı öğrenme (Curriculum Learning) stratejisi ile desteklenmiştir.

Unity oyun motoru üzerinde, harici kütüphane bağımlılığı olmaksızın saf C# ile geliştirilen simülasyon ortamında; Saf RL ve önerilen hibrit model karşılaştırmalı olarak analiz edilmiştir. Ek olarak müfredat eğitiminin katkısı da değerlendirilmiştir. Elde edilen bulgular, güvenlik katmanına sahip hibrit modelin, eğitim kararlılığını önemli ölçüde artırdığını ve RL yaklaşımına kıyasla "intihar oranını" minimize ederken, hedefe ulaşma başarısını önemli ölçüde iyileştirdiğini göstermektedir.

1 Giriş

Yapay zekâ yöntemlerinin oyun dünyasında kullanımı, hem akademik araştırmalar hem de sanayi alanında giderek artan bir önem taşımaktadır. Bu bağlamda bomberman oyunu, hem stratejik planlama gereksinimi hem de anlık hayatta kalma zorunluluğu nedeniyle, pekiştirmeli öğrenme algoritmalarının test edilmesi için ideal bir ortam sunmaktadır.

Geleneksel derin pekiştirmeli öğrenme yaklaşımları, özellikle başlangıç aşamasındaki rastgele keşif süreçlerinde, ajanın sıkça intihar etmesi nedeniyle negatif ödül tuzakına düşmektedir. Bu durum, ajanın yakınsama süresini uzatmakta ve çoğu zaman suboptimal politikaların üretilmesine yol açmaktadır. Literatürde bu zorluklar, ödül şekillendirme veya uzman gösterimi (kaydedilen kazanılmış oyun verileri) gibi yöntemlerle aşılmaya çalışılmış olsa da ajanın kısıtlı işlem kapasitesiyle gerçek zamanlı risk analizi yapabilmesi hala bir problemdir.

Bu makalenin temel katkısı, Bomberman oyunundaki zorlukları aşmak için karar verme sürecini iki katmana ayıran bir mimari önermesidir: Stratejik hamleleri ve hedef takibini yürüten MLP tabanlı bir sinir ağı ve ajanın güvenli bölge bularak hayatta kalmasını garanti altına alan A* tabanlı bir güvenlik katmanı. Ayrıca, ajanın temel na-

vigasyondan karmaşık saldırı stratejilerine aşamalı geçişini sağlayan üç fazlı bir müfredat tabanlı öğrenme stratejisi uygulanmıştır. Çalışmanın kalan bölümleri şu şekilde düzenlenmiştir: Bölüm 2'de ilgili literatürün özeti, Bölüm 3'te önerilen hibrit sistemin teknik mimarisi ve simülasyon parametreleri açıklanmakta, Bölüm 4'te elde edilen verilerin analizi yapılmakta ve Bölüm 5'te gelecek araştırmalar için çıkarımlar sunulmaktadır.

2 İlgili Çalışmalar

Bomberman ve benzeri ortamlar (örneğin Pommerman), çok etmenli yapıları, kısmi gözlemlenebilirlik (partial observability) özellikleri ve gecikmeli ödül mekanizmaları nedeniyle yapay zeka algoritmaları için zorlu test ortamları olarak kabul edilmektedir [1]. Literatürde bu problemleri çözmek için model tabanlı yaklaşımlar, arama algoritmaları ve derin pekiştirmeli öğrenme yöntemleri sıklıkla kullanılmaktadır.

Pekiştirmeli öğrenme yöntemlerinde, ajanın güvenli hareket etmesi ya da hedefe ulaşması konusunda yalnız kullanıldıklarında kararsız davranışlar sergileyebilmektedir. Bu nedenle, literatürde öğrenme algoritmalarının kural tabanlı ya da arama tabanlı yöntemlerle birleştirildiği hibrit yaklaşımlar bulunmaktadır. Monteiro ve arkadaşları [2], bomberman oyununda karar verme süreci için davranış ağaçları (Behavior Trees) ile A* ve genişlik öncelikli arama (BFS) algoritmalarını bir araya getirmiştir. Çalışmada, A* algoritmasının BFS'ye göre daha az düğüm genişleterek hedefe (düşman veya çıkış kapısı) giden en uygun yolu bulmada daha etkili olduğunu göstermektedir. Meisheri ve arkadaşları [1] ise pekiştirmeli öğrenme ile eğitilen bir ajanın intihar eyleminde bulunmasını engellemek amacıyla sezgisel bir eylem filtresi (Action Filter) geliştirmişlerdir. Bu tür hibrit yapılar, ajanın güvenliğini artırarak öğrenme sürecinin verimliliğine katkıda bulunmaktadır.

Pekiştirmeli öğrenme ve MLP tabanlı yöntemler, bomberman oyununda ajanın karar verme süreçlerinde yaygın olarak incelenmektedir. Kormelink ve arkadaşları [3], durum-eylem değer fonksiyonunu temsil etmesi amacıyla MLP kullanan bir Q-öğrenme (Q-Learning) yöntemi geliştirmiş ve farklı keşif stratejilerini karşılaştırarak Max-Boltzmann stratejisinin en yüksek başarıyı elde ettiğini belirtmişlerdir. Başka bir çalışmada ise oyunun RAM bellek verilerini girdi olarak kullanan bir Derin Q-Öğrenme (Deep Q-Learning) yapısı önerilmiş ve bir MLP ile durum-eylem çiftlerini modellemiştir [4]. Marks ve arkadaşları [5] ise klasik Q-Learning ile Deep Q-Learning ajanlarını kar-

şılaştırmış ve Derin Q-Öğrenme yönteminin karmaşık durumlarda daha iyi genelleme yapabilme kapasitesine sahip olduğunu ve kural tabanlı ajanlara kıyasla daha başarılı olduğunu ortaya koymuştur.

Ancak saf RL yöntemleri, Bomberman gibi seyrek ödül yapısına sahip ve hataların (örneğin intihar etme) maliyetli olduğu ortamlarda yavaş yakınsama sorunu yaşamaktadır. Bu sorunu aşmak için müfredat tabanlı öğrenme yaklaşım kullanılmaktadır. Meisheri ve arkadaşları [1], Pommerman ortamında giderek zorlaşan bir rakip müfredatı (hareketsiz ajan, bombasız basit ajan, tam donanımlı ajan) izlemişlerdir. Bu yaklaşımın, ajanın temel becerileri unutmamasını engellediği ve eğitim süresini önemli ölçüde kısalttığı gözlemlenmiştir. Benzer şekilde Gong ve arkadaşları [6], karmaşık hedef-füze-savunma senaryolarında başlangıç koşullarındaki belirsizlik aralığını aşamalı olarak genişleten bir müfredat stratejisinin, seyrek ödüllendirme yapısına rağmen ajanın yakınsama kararlılığını ve genelleme yeteneğini artırdığını göstermiştir. Başka bir çalışmada ise [7], çok etmenli yol bulma problemlerinde (MAPF), eğitim sürecini basit bireysel görevlerden daha karmaşık işbirlikçi görevlere doğru aşamalı bir müfredat temelli öğrenme yöntemi önerilmiş ve bu yöntemin başarı oranını ve çözüm hızını önemli ölçüde artırdığını göstermiştir.

Sonuç olarak, literatürdeki çalışmalar MLP tabanlı pekiştirmeli öğrenmenin karar vermede etkili olduğunu, ancak güvenlik ve gezinme görevleri için A* gibi arama algoritmalarıyla desteklenmesi gerektiğini göstermektedir. Ayrıca, karmaşık görevlerin öğrenilmesinde müfredat tabanlı stratejilerin kararlılığı artırdığı görülmektedir. Bu çalışma, literatürdeki bu üç etkili bileşeni (MLP tabanlı pekiştirmeli öğrenme, A* tabanlı risk haritalama ve Müfredat Tabanlı Öğrenme) tek bir hibrit mimaride birleştirilmesi hedeflenmektedir.


3 Yöntem

Bu bölümde, oluşturulan simülasyon ortamının dinamikleri, önerilen hibrit ağ mimarisinin teknik ayrıntıları, uygulanan eğitim protokolünün adımları ve modelin değerlendirilmesinde kullanılan ölçütler ayrıntılı bir şekilde sunulmaktadır.


3.1 Simülasyon Ortamı

Çalışma, Unity oyun motoru üzerinde geliştirilen ve C# dili ile kodlanan QBombENV isimli özel bir ızgara (grid) ortamında gerçekleştirilmiştir. Bu ortam, ajanın karar verme yetilerini anlık geri bildirimlerle test eden stokastik bir yapıya sahiptir.

- **Ortam Dinamikleri ve Fizik:** Oyun alanı, hesaplama maliyetini optimize etmek ve ajanın yerel etkileşimlerine odaklanmak amacıyla 9x7 (Genişlik x Yükseklik) boyutlarında sınırlandırılmıştır. Dış duvarlar dışında ajan 7x5'lik bir alanda gezinebilmektedir. Ortamda kırılabilir ve kırılmaz duvarlar, bir adet Ajan ve bir adet Hedef (rakip) bulunmaktadır (Şekil 1). Ajan veya hedef tarafından bırakılan bombalar SimpleBomb tarafından yönetilerek 3 adım (step) sonra patlamakta ve hem dikey hem de yatay eksen



Şekil 1: Simülasyon Ortamı



Şekil 2: Gözlem Uzaı Temsili

1 birim etki yaratmaktadır. Bu gecikmeli patlama mekanizması, ajanın sadece anlık durumu değil, gelecekteki durumu da tahmin etmesini zorunlu kılar.

- **Gözlem Uzaı:** Tam gözlemlenebilirliğin aksine, ajan ortamı kısmi bir pencereden algılar. AjanRL içerisinde tanımlanan lokal görüş mekanizması ajanın bulunduğu merkez hücre ve onu çevreleyen 3x3'lük alanın genişletilmiş bir versiyonu içermektedir. Bu hücreler; boşluk, duvar, kırılabilir duvar, bomba ve hedef bilgisi ile beraber bomba sayacı ve tehlikeli mi bilgisini barındırmaktadır. Ek olarak, hedefe olan normalize edilmiş göreceli konum, Manhattan mesafesi ve Pathfinder modülünden gelen anlık bilgiler (teklikede mi, hedefe açık yol varlığı) gibi 5 adet global özellik vektöre eklenmiştir (Şekil 2). Toplamda ise 83 boyutlu ($13 \times 6 + 5$) hibrit bir durum vektörü elde edilir. Bu sıkıştırılmış temsil, ağı gereksiz verilerle boğulmadan (curse of dimensionality) hızlı öğrenmesini sağlar.
- **Eylem Uzaı (A):** 6 farklı hareketten oluşmaktadır:

$$A = \{\text{Yukarı, Aşağı, Sağ, Sol, Bomba Bırak, Bekle}\}$$

- **Ödül Fonksiyonu:** Ajanın optimum stratejiyi öğrenbilmesi için tasarlanan ödül sistemi Tablo 2’de verilmiştir. Ajanın en kısa yolu bulmasını teşvik etmek, intaharı önlemek ve verimliliğini arttırmak amaçlı bir sistem oluşturulmuştur. Ajanın hedefe doğru daha hızlı ilerlemesi için, *Pathfinder* içerisinde A* algoritmasıyla hesaplanan hedefe olan mesafenin artış ve azalışına dayalı bir ödül ceza sistemide eklenmiştir.

Tablo 1: Ödül ve Ceza Sistemi

Olay / Durum	Değer	Açıklama
Hedefe Ulaşma	+200	Hedef ele geçirildiğinde
Ajanın İntiharı	-300	Ajan kendi bombasıyla öldüğünde
Öldürülme	-100	Hedef bombasıyla öldürüldüğünde
Yakın Bomba	+20	Hedef bomba menzilindeyken
Duvar Kırma	+6	Bomba ile kırılan her duvar
Yaklaşma	+0.1	Hedefe yönelik her geçerli adım
Uzaklaşma	-0.05	Hedekten uzaklaşan her adım
Her Adım(Step)	-0.02	Her adım için temel ceza
Tehlikeli Bölge	-0.05	Patlama riski olan karede
Gereksiz Bomba	-0.1 ila -4	Hedef menzilde değil ve duvar kırılmıyorsa
Bekleme	-0.2	Aktif bomba olmadan bekleme
Uzun Bekleme	-0.15	3 adımdan fazla üst üste bekleme

3.2 Ajanın Hibrit Mimari Yapısı

Bu çalışmada ajan, çevresel algılama, karar verme ve güvenlik denetimi süreçlerini birleştiren bir hibrit mimariye sahiptir. Ajanın temel karar mekanizması MLP tabanlı pekiştirmeli öğrenme ile gerçekleştirilirken risk analizi ve güvenliği A* tabanlı bir güvenlik modülü ile desteklenmiştir.

3.2.1 Yapay Sinir Ağı (MLP) Yapısı

Ajanın karar mekanizması, *SimpleMLP* sınıfı ile implemente edilen, özel olarak optimize edilmiş ileri beslemeli bir yapay sinir ağıdır (Multi-Layer Perceptron).

- **Ağ Mimarisi:** Giriş katmanı 85 boyutlu durum vektörünü alır, 64 nöronlu gizli katman (Hidden Layer) ve 6 nöronlu (her bir eylemin Q-değeri için) çıkış katmanından oluşmaktadır.
- **Ağırlık Başlatma:** Ağın eğitimi sırasında gradyanların sönümlenmesini veya patlamasını önlemek amacıyla, ağırlıklar Xavier (Glorot) Uniform dağılımına göre başlatılmıştır. Başlatma aralığı şu formülle belirlenir:


$$W \sim U\left(-\sqrt{\frac{6}{n_{in} + n_{out}}}, \sqrt{\frac{6}{n_{in} + n_{out}}}\right)$$

- **Aktivasyon Fonksiyonu:** Gradyan kaybolma problemini (vanishing gradient) engellemek ve seyrek aktivasyon sağlamak amacıyla ReLU ($f(x) = \max(0, x)$) kullanılmıştır.
- **Optimizasyon Parametreleri:** Optimizasyon sürecinde standart Stokastik Gradyan İnişi (SGD) yerine, kararlılığı artırmak için Momentum ($\mu = 0.9$) ve aşırı öğrenmeyi (overfitting) önlemek için L_2 Regularizasyona karşılık gelen Weight Decay (0.0001) eklenmiştir. Ayrıca, eğitim sırasında gradyan patlamalarını engellemek amacıyla hata terimi $[-100, 100]$ aralığında kırılmıştır.
- **Deneyim Tekrarı (ExperienceReplay sınıfı):** Eğitim stabilitesini artırmak amacıyla kullanılmış, ajanın deneyimleri ($s, a, r, s', done$) 10000 kapasiteli bir bellekte saklanmış ve her adımda rastgele seçilen 32’lik yığınlar (batch) ile SGD uygulanmıştır.

3.2.2 Güvenlik Katmanı ve Risk Haritası

Saf RL algoritmalarında, ajan özellikle eğitim sürecinin başlarında -greedy politikası nedeniyle yüksek olasılıklarla rastgele eylemler gerçekleştirir. Bu aşamada, Bomberman gibi hataların ölümcül sonuçlar doğurduğu oyunlarda, ajanın sürekli kendi kendini sabote etmesine neden olmaktadır. Bu problemin üstesinden gelmek amacıyla bir güvenlik katmanı *SimplePathfinder* entegre edilmiştir.

Ajan her adımda bir eylem seçmeden önce, bulunduğu konumun tehlike durumunu kontrol eder. Tehlike algısı üç faktöre (bomba tehlikesi, çıkmaz sokak, düşmana yakınlık) dayalı bir Risk Haritası ($R(x, y)$) üzerinden kaçış rotası A* algoritması ile hesaplanır.



Şekil 3: Risk Haritası ve Güvenli Bölge 5x5 alan temsili Gösterimi

A* algoritmasının maliyet fonksiyonu ($f(n)$), standart $g(n)$ (başlangıçta uzaklık) ve $h(n)$ (hedefe sezgisel uzaklık)

değerlerine ek olarak risk maliyetini de içerir:

$$f(n) = g(n) + h(n) + R(n)$$

Eğer ajan bir tehlike bölgesindeyse, sınır ağının çıktısı (Q -değerleri) göz ardı edilir ve A^* algoritması tarafından hesaplanan en güvenli hücreye yönlendiren eylem devreye girer (Şekil 3). Bu sayede ajan, hayatta kalmayı garanti eder.

3.2.3 Eylem Seçimi ve Hiperparametre Yönetimi

Ajanın öğrenme sürecinde keşif ve sömürü dengesini optimize etmek ve öğrenme verimliliğini artırmak amacıyla gelişmiş bir eylem seçim mekanizması uygulanmıştır. Bu mekanizma, kısıtlı eylem uzayı (action masking) ve aşamalı müfredat tabanlı epsilon azalımı prensiplerine dayanmaktadır.

- **Eylem Maskeleye ve Geçersiz Hamle Engelleme:** Duvar veya harita sınırı olan yönlerin Q -değerleri $-\infty$ atanır. Eğer aktif bomba varsa (`env.bombActive`), yeni bomba bırakma eyleminin Q -değerine $-\infty$ atanır. Bu sayede bu hamleler geçersiz kılınır ajan diğer hamleler üzerinden seçim gerçekleştirir.
- **Müfredat Tabanlı Epsilon-Greedy Stratejisi**
Keşif oranı ϵ eğitim fazlarına göre dinamik güncellenir:
 - **Faz 1 (Hızlı Keşif):** Epsilon (ϵ) başlangıçta 1.0 olup 0.9925 katsayısı ile hızla düşürülür ve 0.05 minimum değerde durdurulur.
 - **Faz 2 (Orta Keşif):** ϵ değeri 0.8 seviyesinden başlatılarak 0.997 oranda düşürülerek 0.05 de sabitlenir.
 - **Faz 3 (Yavaş Keşif):** ϵ 0.6 ile başlar, 0.9991 katsayısı ile yavaşça düşürülür ve 0.05 minimum değerde durdurularak sömürü arttırılır.
- **Hiperparametre Ayarları:** Modelin eğitimi sırasında kullanılan temel hiperparametreler:
 - **Öğrenme Oranı (α):** Sinir ağı ağırlık güncelleme hızı 0.0001 seçilmiştir.
 - **İndirim Faktörü (γ):** Gelecekteki ödüllerin bugünkü değere etkisi 0.99 seçilmiştir.
 - **Maksimum Bölüm (Episode):** Toplam eğitim döngüsü 4000 belirlenmiştir.

3.3 Müfredat Tabanlı Öğrenme

Ajanın karmaşık davranışları öğrenebilmesi için eğitim süreci `CurriculumTarget` sınıfı ile üç aşamalı bir müfredat tabanlı öğrenme stratejisi tasarlanmıştır. Bu yaklaşım, öğrenme problemini kolaydan zora doğru parçalayarak ajanın yerel minimumlara takılmasını engellemeyi amaçlamaktadır.

- **Faz 1 (Sabit Hedef - 500 Bölüm):** Hedef hareket-siz durumdur. Ajan, temel navigasyon becerilerini, duvarları aşmayı ve hedefe yönelmeyi öğrenir.

- **Faz 2 (Rastgele Hedef - 1000 Bölüm):** Hedef, ajandan kaçma eğilimindedir. Amaç, ajanın hareketli bir hedefi takip etme ve köşeye sıkıştırma yeteneğini geliştirmektir.

- **Faz 3 (Saldırgan Hedef - 2500 Bölüm):** Rakip, `aggressionLevel = 0.7` ve `randomnessFactor = 0.3` değerleriyle Hedef hem savunma yapar hem de ajana karşı bomba bırakarak saldırır. Ayrıca, ajanın hedefin hareketlerini ezberlememesi için %30 olasılık ile rastgele hareket etmesi sağlanır. Bu faz, ajanın hayatta kalma ve karşı saldırı taktiklerini geliştirmektedir.

Müfredat geçişleri, her aşama belirli bir bölüm (episode) tamamlandığında otomatik olarak bir sonrakine geçmektedir.

3.4 Eğitim Süreci ve Model Varyasyonları

Güvenlik Katmanı (Safety Layer) ve Müfredat Yapısının (Curriculum) performansa olan bireysel etkilerini ayrı ayrı değerlendirebilmek için 4 farklı model konfigürasyonu eğitilmiştir. Her bir model aynı parametrelerle eğitilmiş olup sadece müfredat yapısı kapalıyken epsilon stratejisi yerine sabit bir azalma (0.9992) verilmiştir. Eğitilen model varyasyonları şunlardır:


- **Müfredat ve Güvenliği Olmayan Model:** Güvenlik katmanı (`useSafetyRule=false`) ve müfredat (`curriculumEnabled=false`) devre dışıdır. Ajan, eğitimin en başından itibaren karmaşık ortamda (Faz 3 zorluğunda) hayatta kalmayı öğrenmeye çalışır.
- **Sadece Güvenlikli Model:** Sadece Pathfinder güvenlik katmanı aktiftir. Müfredat kapalıdır. Amaç, güvenlik katmanının öğrenme hızına etkisini ölçmektir.
- **Sadece Müfredatlı Model:** Güvenlik katmanı açıktır, ancak ajan eğitimin başından zorlu fazda başlatılan bir eğitim sürecinden geçer.
- **Hibrit - Önerilen Model:** Hem güvenlik katmanı hem de müfredat aktiftir. Bu çalışmanın nihai önerisi olan ve aşağıdaki test senaryolarında performansı detaylandırılan ana modeldir.

4 Deney Sonuçları ve Analiz

Önerilen hibrit mimarının etkinliğini doğrulamak amacıyla 4 farklı eğitim aşaması yapılmıştır. Elde edilen model sonuçlarını değerlendirmek üzere `CurriculumTarget` tarafından yönetilen ve zorluk seviyesi değişen 6 farklı senaryo oluşturulmuştur. Her senaryo için 100 farklı bölüm çalıştırılmış ve performans metrikleri (Başarı Oranı, İntihar Oranı, Ortalama Adım Sayısı) raporlanmıştır.

4.1 Eğitim Performansı Karşılaştırması

Eğitim sürecinde toplanan veriler Şekil 3'te karşılaştırılmıştır. Bu verilere dayanarak, güvenlik odaklı yöntemlerin güvenliksiz yöntemlere kıyasla önemli bir başarı gösterdiği görülmektedir. Ancak, müfredat tabanlı sistemin eğitime önemli bir katkı sağlamadığı gözlemlenmiştir.



Şekil 4: 4 Modelin; Ödül ve Adım Sayısı ile Kazanma, İntihar ve Öldürülme Oranları

4.2 Test Senaryoları

Modelin farklı zorluk seviyelerine ve rakip stratejilerine adaptasyonunu ölçmek için kurgulanan 6 farklı test senaryosunun teknik detayları ve amaçları Tablo 2’te sunulmuştur. İlk üç senaryo (S1-S3) müfredat fazlarına odaklanırken, son üç senaryo (S4-S6) Faz 3 içerisindeki Hedef agresifliğinin etkilerini incelemektedir.

5 Tartışma

Elde edilen bulgular, Bomberman gibi hatanın ölümcül olduğu ortamlarda kural tabanlı güvenlik katmanlarının (Safety Layer) kritik bir öneme sahip olduğunu kanıtlamaktadır.

Güvenlik Katmanının Rolü: Şekil 4’teki veriler, güvenlik katmanının ajanı rastgele keşif aşamasındaki anlamsız ölümlerden koruyarak, sinir ağının daha anlamlı durum-eylem çiftlerini öğrenmesine odaklanmasını sağladığını göstermektedir.

Tablo 2: Test Senaryo Detayları


Senaryo Açıklama	
S1:	Faz 1 (Phase=1) Hedef: Hareketsiz Ajanın duvarları aşarak en kısa yolu bulma ve 3 adımlık bomba patlama süresini yönetme becerisinin, herhangi bir dış tehdit olmadan doğrulanması.
S2:	Faz 2 (Phase=2) Hedef: Rastgele Gezin Sürekli yer değiştiren (MoveRandomly) bir hedefe karşı takip ve “köşeye sıkıştırma” stratejilerinin dinamik testi.
S3:	Faz 3 (Phase=3, agresiflik=0.7, bomba=0.4) Hedef: Dengeli Standart oyun mekaniklerinde ajanın genel ofansif/defansif strateji başarısının referans (baseline) ölçümü.
S4:	Faz 3 (agresiflik ve bomba=0.2) Bomba Olasılığı: Düşük Sürekli kaçan hedefe karşı ajanın sabrını ve takip ısrarını ölçer. Hedef nadiren bomba bıraktığı için ölüm riski düşüktür.
S5:	Faz 3 (agresiflik=0.6 ve bomba=0.6) Bomba Olasılığı: Orta Eğitim veri dağılımına en yakın senaryodur; optimum saldırı-savunma geçişlerini ve genel oyun performansını test eder.
S6:	Faz 3 (agresiflik ve bomba=1.0) Bomba Olasılığı: Yüksek İntihar pahasına saldıran hedefe karşı Güvenlik Katmanı (Safety Layer) ve Pathfinder kaçış rotası hesaplamasının limitlerini zorlayan stres testidir.

Müfredat Öğreniminin Etkisi: Analizler sonucunda, müfredat tabanlı eğitimin bu spesifik senaryoda beklene- nin aksine başarı oranına anlamlı bir katkı sağlamadığı gözlemlenmiştir. Bu durumun sebebi, kullanılan güvenlik katmanının zaten ajanı karmaşık durumlarda koruması ve eylem maskeleyen eylem uzayını yeterince daraltması ile açıklanabilir.

Hesaplama Maliyeti: A* algoritmasının her adımda çalıştırılması, saf bir sinir ağına göre düşük bir hesaplama yükü getirir de, ajanın hayatta kalma süresini uzattığı için toplam eğitim verimliliğini artırmıştır.

6 Sonuç ve Gelecek Çalışmalar

Bu çalışmada, derin pekiştirmeli öğrenme ile A* tabanlı risk haritalama yöntemlerini birleştiren hibrit bir ajan mimarisi geliştirilmiştir. Sonuçlar, güvenlik katmanı entegrasyonunun ajan başarısını ve eğitim kararlılığını saf RL yöntemlerine göre önemli ölçüde artırdığını göstermiştir. Özellikle agresif rakiplere karşı ajanın hayatta kalma becerisi, risk tabanlı karar mekanizması sayesinde optimize edilmiştir.



Şekil 5: Test Sonuclari

Gelecek çalışmalarda;

- Ajanın daha iyi performans sağlaması için eğitim parametrelerinin ve ödül fonksiyonunda iyileştirmeler,
- Ajanın kısmi gözlemlenebilirlik durumunda daha iyi performans sergilemesi için Evrişimli Sinir Ağları (CNN) veya Uzun-Kısa Süreli Bellek (LSTM) birimlerinin mimariye eklenmesi,
- Çok etmenli (multi-agent) ortamlarda iş birlikçi saldırı stratejilerinin geliştirilmesi hedeflenmektedir.

Kaynaklar

- [1] Meisheri, H., Shelke, O., Verma, R., & Khadilkar, H. (2019). Accelerating training in pommerman with imitation and reinforcement learning. *arXiv preprint arXiv:1911.04947*, s.1.
- [2] Monteiro, J., Granada, R. L., Pinto, R., & Barros, R. C. (2018). Beating bomberman with artificial intelligence. *Anais do XV Encontro Nacional de Inteligência Artificial e Computacional (ENIAC 2018)*, Brasil.
- [3] Groot Kormelink, J. G. C. (2017). Comparison of Exploration Methods for Connectionist Reinforcement Learning in the game Bomberman. Doctoral dissertation, Faculty of Science and Engineering, University of Groningen.
- [4] Gray, A. (2019). Super Bomberman: Q-learning with deep artificial neural networks for the Bomberman video game.
- [5] Marks, L., Pfeil, J., & Richter, M. (2021). Reinforcement Learning for Bomberman. Universität Heidelberg.
- [6] Gong, X., Chen, W., Chen, Z. (2023). Intelligent game strategies in target-missile-defender engagement using curriculum-based deep reinforcement learning. *Aerospace*, 10(2), 133.

- [7] Zhao, C., Zhuang, L., Huang, Y., Liu, H. (2023, June). Curriculum learning based multi-agent path finding for complex environments. In *2023 International Joint Conference on Neural Networks (IJCNN)* (pp. 1-8). IEEE.