

Dinamik Ortamlarda Pekiřtirmeli Öğrenme: Hibrit Bomberman Ajanı

Bilgisayar Oyunlarında Yapay Zeka

Hazırlayan
Çağla Ökmen



Projenin Özeti ve Kullanılan Yöntemler

Bu proje, Unity oyun motorunda Bomberman tarzı bir grid-based ortamda özgün bir derin pekiştirmeli öğrenme (Deep Reinforcement Learning - DRL) ajanının geliştirilmesini içermektedir. Ajan, hareket kararları almak, bomba yerleştirmek ve dinamik bir hedefi etkisiz hale getirmek için özel tasarlanmış bir Multi-Layer Perceptron (MLP) sinir ağı kullanmaktadır.

Kullanılan Yöntemler:

Çok Katmanlı Algılayıcı (MLP)

- Görevi:** Karar verme ve değer fonksiyonu tahmini

Derin Pekiştirmeli Öğrenme (RL)

- Görevi:** Ödül maksimizasyonu ile strateji öğrenme

A* Yol Bulma Algoritması

- Görevi:** Risk analizi ve güvenli kaçış yolları

Ortam Simülasyonu


Izgara Temsili (Grid Representation): Oyun alanı 7x7 boyutlarında bir matris (int[,] map) üzerinde tutulmaktadır.

Ortam Özellikleri:

- **Dinamik Ortam:** Hareketli hedef, patlayan bombalar
- **Kısmi Gözlemlenebilirlik:** Sadece 3x3 alanı görülebilir
- **Yüksek Risk:** Kendi bombasıyla ölme olasılığı
- **Stratejik Kararlar:** Bomba zamanlaması ve yerleştirme

Eylem Uzayı:

- Yukarı Git
- Aşağı Git
- Sağa Git
- Sola Git
- Bomba Koy
- Bekle



Yapay Sinir Ağı Mimarisi

Ağ ağırlıkları, öğrenmenin başlangıcında "patlayan gradyan" (exploding gradients) sorununu önlemek için Xavier/Glorot Initialization mantığına benzer bir yöntemle, girdi ve çıktı boyutuna göre ölçeklendirilmiş rastgele değerlerle başlatılır.

Katman Yapısı:

- **Girdi Katmanı (Input Layer):** Ajanın çevresini algılayan "Spatial Encoding" (Konumsal Kodlama) verilerini alır.
- **Gizli Katman (Hidden Layer):** 64 nöronlu, doğrusal olmayan problemleri çözebilmek için ReLU (Rectified Linear Unit) aktivasyon fonksiyonunu kullanan katmandır.
- **Çıktı Katmanı (Output Layer):** 6 adet olası aksiyon (Yukarı, Aşağı, Sağ, Sol, Bomba, Bekle) için ham Q değerlerini üreten katmandır.

Optimizasyon Tekniği (Momentum):

- Standart gradyan inişi (SGD) yerine, yerel minimumlara takılmayı önlemek ve öğrenmeyi hızlandırmak için Momentum tabanlı güncelleme kullanılmıştır.
- Ağ, velocity dizileri sayesinde önceki gradyan değişimlerini hafızada tutarak ağırlık güncellemelerine ivme kazandırır.
- **Aktivasyon Fonksiyonu:** Gizli katmanda ReLU (Negatifleri sıfırla, pozitifleri geçir).
- **Gradient Clipping:** Hata değerleri -1 ile 1 arasına sıkıştırılarak eğitimin kararlılığı sağlanmıştır.

Ajan Dünyayı Nasıl Görüyor?


Lokal Görüş (Spatial Encoding): Ajanın çevresindeki 3x3'lük alan taranır. Grid üzerindeki nesnelerin sadece "ne" olduğu değil, "nerede" olduğu bilgisi ağıya verilir.

Global Görüş: Ajanın ve hedefin normalize edilmiş konumu ve hedefe olan Manhattan Mesafesi.

Veri Kodlama (One-Hot Encoding): Her bir kare için nesne analizi yapılır;

- Duvar mı?
- Kırılabilir mi?
- Bomba var mı?
- Hedef burada mı?

Sinir Ağına Giriş (Input Vector): Bu veriler düzleştirilerek 59 boyutlu (float) bir vektör haline getirilir ve MLP'nin giriş katmanına beslenir.



Pekiştirmeli Öğrenme Stratejisi

Ajan, çevreden aldığı durumlara (State) karşılık en yüksek ödülü getirecek aksiyonu (Action) seçmeyi öğrenir. Hedef Q değeri hesaplanırken Bellman Denklemi referans alınır: $\text{Target} = R + \gamma \cdot \max(Q_{\text{next}})$.

Action Masking (Aksiyon Filtreleme):

- Öğrenme sürecini hızlandırmak için ajanın "imkansız" veya "mantıksız" hamleler yapması matematiksel olarak engellenir.
- Örneğin; duvar olan bir yöne gitmesi, zaten bomba olan yere tekrar bomba koymaya çalışması veya takılması durumunda o aksiyonun Q değeri -sonsuz (NegativeInfinity) yapılarak seçilmesi engellenir.

Experience Replay (Deneyim Tekrarı):

- Ajanın yaşadığı olaylar (Durum, Aksiyon, Ödül, Sonraki Durum) dörtlüsü olarak 10.000 kapasiteli bir hafıza tamponunda (Replay Buffer) saklanır.
- Eğitim sırasında bu hafızadan rastgele örneklemeler (batch) çekilerek, ardışık verilerin oluşturduğu korelasyon (unlearning) sorunu çözülür.

Keşfet-Sömür (Exploration vs. Exploitation):

- Epsilon-Greedy stratejisi ile eğitim başında %100 rastgele hareket eden ajan, epsilonDecay çarpanı ile zamanla öğrendiği bilgileri kullanmaya başlar.

Ödül Mekanizması

Durum / Olay	Ödül Değeri	Açıklama
Hedefi Yok Etme	200	Bölümün başarıyla tamamlanması.
Ajanın Ölümü	-300	Ajanın kendi bombasıyla ölmesi.
Stratejik Bomba	20	Hedef, bırakılan bombanın patlama menzilineyse verilir.
Gereksiz Bomba	-2	Hedef yakınken (3 birim) ancak menzilde değilken riskli bomba koymak.
Duvar Kırma	5	Patlama menzilinedeki her bir kırılabilir duvar için verilir.
Hedefe Yaklaşma	0.05	A* algoritmasına göre hedefe olan yol kısaldığında verilir.
Hedekten Uzaklaşma	-0.1	Ajan hedekten uzaklaşırsa verilir.
Akıllı Bekleme	0.1	Bomba aktifken güvenli bir yerde bekliyorsa teşvik edilir.
Hatalı Bekleme	-5	Ortada bomba yokken (tehlike yokken) boşuna beklemek.
Yaşam Cezası (Step)	-0.05	En kısa sürede bitirmeyi teşvik etmek için her adımda kesilen puan.

A* Tabanlı Mesafe Ölçümü

Hedefe yakınlık kuş uçuşu mesafe (Euclidean) yerine, gerçek yürüyüş mesafesi ile hesaplanmaktadır. Her adımdan önce (oldDistance) ve sonra (newDistance) hedefe olan en kısa yol hesaplanır. Bu sayede hedefe yaklaşmayı öğrenir.

Hedefe olan mesafeyi ölçmek için sıralı iki farklı analiz yapar:

- **Açık Yol Analizi:**
 - Bomba kullanmadan hedefe ulaşabileceği rotayı hesaplar.
- **Potansiyel (Kırılabilir) Yol Analizi:**
 - İlk aşama başarısız olursa, ikinci bir A* taraması yapılır. Bu modda algoritma, Kırılabilir Duvarları sanki düz zeminmiş gibi (ancak biraz daha maliyetli) kabul eder ve "içinden/üzerinden" geçer.
 - Maliyet Hesabı: `if (env.map[...] == 1) newGCost += 2;` kodu ile duvar kırmanın zaman alacağı hesaba katılır, böylece ajan gereksiz duvar kırmaktansa açık yolu tercih etmeye zorlanır.

Kırılabilir Yol hesabı sayesinde ajan, duvarın yanına geldiğinde "Potansiyel olarak hedefe yaklaştım" diyerek ödül alır ve duvarı kırma motivasyonu kazanır.

Hibrit Güvenlik Modülü (A*)

Saf RL algoritmaları, özellikle bomba patlama süresi gibi gecikmeli cezalarda (delayed punishment) hayatta kalmayı öğrenmekte zorlanabilir. Bu yüzden deterministik bir algoritma ile desteklenmiştir.

Risk Analizi ve Müdahale:

- Ajan her adımda önce SimplePathfinder modülünü çalıştırarak bir Risk Haritası oluşturur.
- Eğer ajan, bir bombanın patlama menzili içindeyse (IsInDanger), RL algoritması (Yapay Sinir Ağı) devre dışı bırakılır.


A* Kaçış Rotası:

- Tehlike anında kontrolü A* Algoritması devralır. Ajanın bulunduğu konumdan, patlama menzili dışındaki en yakın "güvenli kareye" en kısa yol hesaplanır.
- Bu sayede ajan, stratejik kararları (duvar kırma, düşmanı sıkıştırma) Sinir Ağı ile verirken; hayatta kalma reflekslerini A* ile gerçekleştirir.

A* risk maliyeti hesabı:

- Bomba Tehlikesi: +50 Puan
- Düşman Yakınlığı: +15 Puan
- Kör Nokta (Dead End): +20 Puan

$$\text{Cost} = g(n) + h(n) + \text{risk}(n)$$



Eğitim Stratejisi

Ajanın öğrenmesini hızlandırmak için zorluk seviyesi kademeli olarak artırılmıştır.

Faz 1 (Episode 1-500)

Hedef: Sabit durur.

Amaç: Ajanın temel hareketleri, duvar kırmayı ve bomba koymayı öğrenir.

Faz 2 (Episode 501+)

Hedef: Rastgele ve kaçınan hareket eder.

Amaç: Ajanın hareketli hedeflere karşı strateji geliştirmesi ve tahmin yeteneği kazanması.






Eğitim Sonuçların Değerlendirilmesi

Öğrenme Başarısı (Reward Convergence):


- İlk 200 episode yüksek varyans (dalgalanma) görülürken, ilerleyen aşamalarda ortalama ödül +200 seviyesine (Kazanma Ödülü) sabitlenmiştir.

Verimlilik Artışı (Step Count Optimization):

- Eğitimin başında ajan hedefi bulmakta zorlanıp zaman aşımına (400 adım) uğramaktadır.



Eğitim Aşaması



Test Sonuçlarının Değerlendirilmesi

Reinforcement Learning Eğitim Performansı

Öğrenme Başarısı (Reward Convergence):

- 50 Testte ortalama 200 lerde ödül başarıları almıştır.


Verimlilik Artışı (Step Count Optimization):

- Testlerde zaman aşımına uğramamıştır ve genelde 100 adımdan az bir sürede başarı elde etmiştir

Episode vs Toplam Ödül (Öğrenme Eğrisi)



Episode vs Adım Sayısı




Aşamalı Testler


3 Farklı Senaryo: Ajanın genel geçerliliğini (generalization) ölçmek için üç farklı ortam 50 kez çalıştırılarak test edilmiştir:

- **Static (Statik):** Hedef sabittir. Temel mekanik ve saldırı hassasiyetini ölçer.
- **Dynamic (Dinamik):** Hedef kaçır. Takip yeteneği ve hareketli hedef isabet oranını ölçer.
- **Hard (Zorlu):** Harita engellerle doludur ve hedef aktiftir. Karmaşık yol bulma ve stratejik karar vermeyi ölçer.


Adım Sayısı Dağılımı (Düşük = Hızlı)



Sonuç Dağılımı (Kazanma / Ölüm / Zaman Aşımı)



Test Aşaması



Thanks.

QBomb

Presented by
Çağla Ökmen